Corporación Universitaria Iberoamericana

Sandra Bautista

Profesor

Damián Felipe Bernal Rodriguez

Angel Alonso Peraza Gutierrez

Estudiante

Ingeniera de software

Inteligencia artificial

Actividad 3 - Métodos de aprendizaje supervisado

Bogotá, Colombia

2026

Contenido

Introducción 3

Identificación y descripción de las fuentes de datos 3

Fuente de datos utilizada 3

Variables del dataset 4

Ejemplo de los datos 4

Desarrollo del modelo de aprendizaje automático 5

Tipo de aprendizaje 5

Algoritmo utilizado 6

Separación de los datos 7

Entrenamiento del modelo 7

Predicción 7

Evaluación del modelo 8

Funcionamiento general del sistema 9

Link del video 10

Link del repositorio 10

Introducción

La inteligencia artificial permite desarrollar sistemas capaces de analizar información, identificar patrones y generar predicciones a partir de los datos disponibles. Uno de sus enfoques es el aprendizaje supervisado, en el que un modelo aprende de ejemplos que incluyen tanto las características de entrada como el resultado esperado.

En actividades anteriores, se desarrolló un sistema inteligente para determinar la mejor ruta entre dos estaciones de una red de transporte público, basándose en una base de conocimientos, reglas lógicas y un motor de inferencia.

Esta actividad se enmarca en el mismo contexto, pero implementa un método de aprendizaje supervisado. Ante la falta de una fuente de datos reales que contenga todas las variables necesarias para el entrenamiento del modelo, se crea un conjunto de datos sintéticos a partir de información sobre las rutas de la red de transporte.

El objetivo del modelo será aprender la relación entre diversas características de las rutas y el tiempo de trayecto, para así poder realizar predicciones sobre nuevas rutas.

Identificación y descripción de las fuentes de datos

Fuente de datos utilizada

Para desarrollar el modelo de aprendizaje supervisado, se creó un conjunto de datos sintético basado en el sistema de transporte público utilizado en actividades anteriores.

Este conjunto de datos se generó mediante simulación, ya que no existía ninguna fuente de datos reales que reuniera todas las variables necesarias para el ejercicio.

Los datos representan diversas rutas que conectan estaciones identificadas con números del 1 al 8. Se descartó el uso de nombres de estaciones reales para mantener la representación adoptada en el proyecto anterior.

La información contenida en el conjunto de datos refleja diversas características que pueden influir en el tiempo de desplazamiento de un vehículo o de un usuario dentro del sistema de transporte.

Variables del dataset

El conjunto de datos contiene las siguientes variables:

Variable	Descripción	Tipo
origen	Número de la estación donde inicia el recorrido.	Entero
destino	Número de la estación donde termina el recorrido.	Entero
distancia_km	Distancia aproximada entre el origen y el destino.	Decimal
hora	Hora aproximada en la que se realiza el recorrido.	Entero
demanda	Cantidad estimada de pasajeros o nivel de demanda del recorrido.	Entero
transbordos	Cantidad de transbordos realizados durante el recorrido.	Entero
tiempo_min	Tiempo total del recorrido expresado en minutos.	Decimal/Entero

La variable tiempo_min corresponde a la **variable objetivo**, ya que representa el valor que el modelo debe aprender a predecir.

Las demás variables corresponden a las **variables de entrada** utilizadas para realizar la predicción.

Ejemplo de los datos

Una muestra del dataset es la siguiente:

Origen	Destino	Distancia (km)	Hora	Demanda	Transbordos	Tiempo (min)
1	2	1.2	7	80	0	5
1	7	2.1	7	65	0	8
2	3	1.0	8	90	0	4
3	4	1.3	8	110	0	5
4	5	1.8	9	70	0	6
5	6	1.1	9	60	0	4
6	8	2.5	10	75	0	12
7	8	3.0	10	55	0	15

Estos datos son **simulados con fines académicos** y no representan mediciones oficiales del sistema de transporte.

Desarrollo del modelo de aprendizaje automático

Tipo de aprendizaje

El problema planteado corresponde a un modelo de aprendizaje supervisado, debido a que el dataset contiene ejemplos en los cuales conocemos las características de entrada y también el resultado esperado.

En este caso:

Variables de entrada:

- Origen.
- Destino.
- Distancia.
- Hora.
- Demanda.

- Númeo de transbordos.

Variable objetivo:

- Tiempo de recorrido en minutos.

El modelo recibe ejemplos de recorridos anteriores y aprende patrones que relacionan las variables de entrada con el tiempo de recorrido.

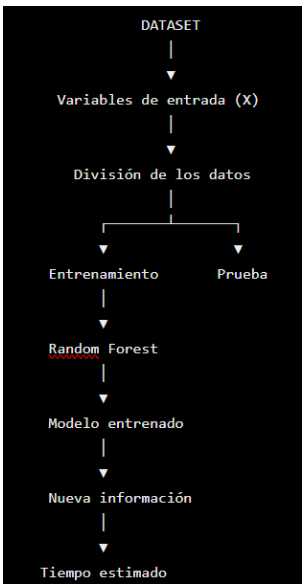
Posteriormente puede utilizar ese conocimiento para estimar el tiempo de un nuevo recorrido.

Algoritmo utilizado

Para desarrollar el modelo se utiliza el algoritmo Random Forest Regressor.

Random Forest es un algoritmo de aprendizaje automático que emplea varios árboles de decisión para realizar predicciones. En este caso, se utiliza la versión de regresión, ya que la variable que se desea predecir es un valor numérico: el tiempo de trayecto en minutos.

Su funcionamiento general puede representarse de la siguiente manera:



Separación de los datos

Antes de entrenar el modelo, el conjunto de datos se divide en dos grupos:

- Datos de entrenamiento: utilizados por el algoritmo para aprender.
- Datos de prueba: utilizados posteriormente para evaluar el rendimiento del modelo.

El programa utiliza:

test_size=0.2

Esto significa que aproximadamente el 80 % de los datos se utiliza para el entrenamiento y el 20 % restante para la prueba.

Esta separación permite verificar el rendimiento del modelo con datos que no se utilizaron directamente durante el entrenamiento.

Entrenamiento del modelo

El entrenamiento se realiza mediante el comando:

model.fit(X_training, y_training)

Durante este proceso, el algoritmo recibe variables de entrada y resultados conocidos.

El modelo analiza los ejemplos disponibles para identificar relaciones y patrones entre las características como la distancia, la hora, la demanda y los transbordos y el tiempo de trayecto.

Predicción

Una vez entrenado el modelo, es posible introducir las características de un nuevo trayecto.

Por ejemplo:

- Origen: 1
- Destino: 8
- Distancia: 3,5 km
- Hora: 8
- Demanda: 100
- Transbordos: 1

El modelo utiliza lo aprendido durante el entrenamiento para generar una estimación del tiempo de trayecto.

El resultado se muestra en minutos.

Evaluación del modelo

Para evaluar el modelo se utilizan dos métricas:

Error medio absoluto — MAE

El MAE representa el error promedio entre los valores reales y los valores predichos.

Por ejemplo, si el modelo obtiene un MAE de 2 minutos, significa que sus predicciones presentan un error absoluto promedio aproximado de 2 minutos sobre los datos de prueba.

Mientras menor sea el MAE, menor será el error promedio de las predicciones.

Coeficiente de determinación — R^2

El coeficiente R^2 permite analizar qué tan bien el modelo explica la variación presente en los datos.

Su valor puede interpretarse de forma general de la siguiente manera:

- Un valor cercano a 1 indica un buen ajuste.
- Un valor cercano a 0 indica poca capacidad explicativa.
- Un valor negativo puede indicar un modelo con un desempeño deficiente respecto al promedio de los datos.

Debido a que el dataset utilizado en este ejercicio es pequeño y sintético, las métricas obtenidas deben interpretarse únicamente como una demostración académica del funcionamiento del modelo y no como una evaluación de un sistema de transporte real.

Funcionamiento general del sistema

El funcionamiento completo del programa puede resumirse en los siguientes pasos:

1. Se crea el dataset sintético.
2. Se almacenan los datos en un DataFrame de Pandas.
3. Se seleccionan las variables de entrada.
4. Se establece el tiempo de recorrido como variable objetivo.
5. Se divide el dataset en datos de entrenamiento y prueba.
6. Se crea el modelo Random Forest.
7. Se entrena el modelo con los datos de entrenamiento.
8. Se realizan predicciones utilizando los datos de prueba.
9. Se calcula el MAE y el R^2.

10. Se introduce un nuevo recorrido.

11. El modelo estima el tiempo de recorrido para ese nuevo caso.

Link del video

https://youtu.be/jPtjsnWdL9o

Link del repositorio

https://github.com/AKIN011/Metodos-de-aprendizaje-supervisado.git